

Machine Learning y aplicaciones en Física

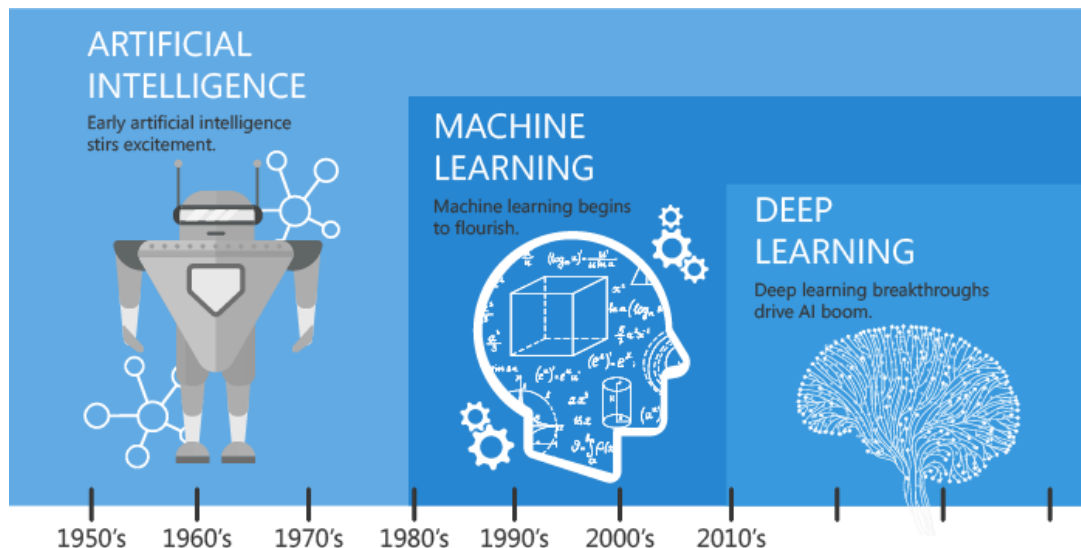
Diego A. Barbosa Trujillo

Universidad de los Andes

7 de febrero de 2020



Seminario de Mecánica Cuántica y Teoría de la Información.

Machine Learning

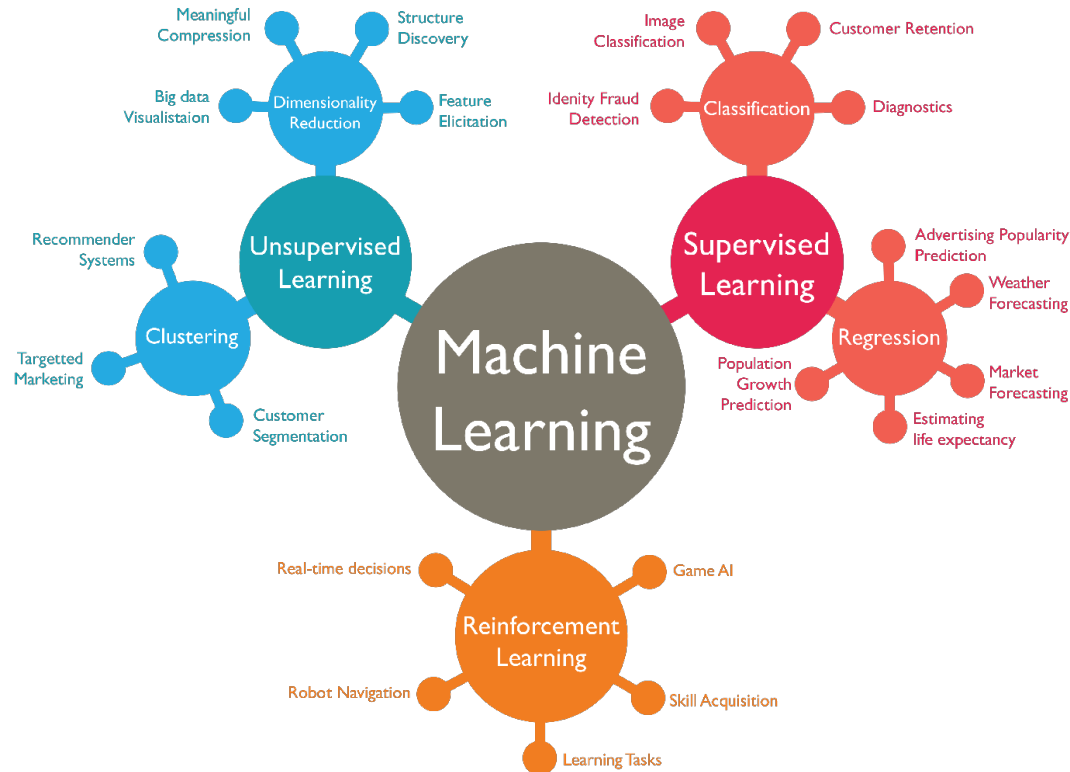


- Arthur Samuel. IBM 1959.
- Hopfield, Rumelhart and Hinton. 1980.
- LeCun, Hinton and Bengio, 2010-Hoy.

Machine Learning




Machine Learning



Machine Learning



Machine Learning




Regresión lineal

En los algoritmos de Machine Learning tendremos:

- Una serie de datos u observaciones: \mathbf{X}
- Un conjunto de funciones f_{θ^*}
- Una función de costo \mathcal{C}

Regresión lineal



La cual sabemos se puede expresar como:


$$y = \Theta^T \mathbf{x} + \eta$$

Regresión lineal

Para aprender los parámetros que describen las observaciones en regresión lineal, tenemos la función de costo de mínimos cuadrados:

$$OLS = \operatorname{argmin}_{\Theta} \|\mathbf{y} - \Theta^T \mathbf{x}\|_2^2 \quad (1)$$

la cual es una función convexa



Usando las reglas de cálculo y un poco de álgebra, encontramos una solución cerrada a este problema

$$\Theta^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (2)$$

Sin embargo en el mundo real, la cantidad de datos es muy grande y para encontrar su solución se utilizan algoritmos como:

- Descenso de gradiente.
- Descenso de gradiente estocástico.

En muchas ocasiones la simple función de costo no se ajusta correctamente y debemos realizar una regularización sobre los parámetros.

$$\Theta_{Ridge}^* = \underset{\Theta}{\operatorname{argmin}} (||\mathbf{y} - \Theta^T \mathbf{x}||_2^2 + \lambda ||\theta||_2^2) \quad (3)$$

o


$$\Theta_{Lasso}^* = \underset{\Theta}{\operatorname{argmin}} (||\mathbf{y} - \Theta^T \mathbf{x}||_2^2 + \lambda ||\theta||_1) \quad (4)$$

Aplicación en Mecánica Estadística

Regresión Lineal y Cadena de Ising 1D

Imaginemos que tenemos un ensemble de diferentes configuraciones de espines y su correspondiente energía en una dimensión, dada por:

$$H = -J \sum_{j=1}^L S_j S_{j+1} \quad (5)$$



Regresión Lineal y Cadena de Ising 1D

Supongamos que nos tenemos un conjunto de datos $D = (\{S_j\}_{j=1}^L, E_j)$ y nuestro objetivo es utilizar regresión lineal para encontrar la constante de acoplamiento J . Para este propósito proponemos un modelo de la forma

$$H_{\text{modelo}}[S^i] = \sum_j^L \sum_k^L J_{i,k} S_j^i S_k^i \quad (6)$$


El cual podemos escribir como

$$H_{\text{modelo}}[S^i] = \mathbf{X}^i \cdot \mathbf{J}, \quad (7)$$

donde X^i representa todas las interacciones de dos cuerpos $\{S_j^i S_k^i\}$ y el índice i corre sobre todos el conjunto de datos.

Regresión Lineal y Cadena de Ising 1D

Para este problema utilizamos 10000 cadenas aleatorias de Ising de longitud 40, y aplicando regresión lineal encontramos:



Regresión Logística

Regresión logística

Para entender la regresión logística, consideremos un sistema de dos estados cuyas energías son E_0 y E_1 , la probabilidad de que el sistema esté en un estado de energía E_0 es

Para entender la regresión logística, consideremos un sistema de dos estados cuyas energías son E_0 y E_1 , la probabilidad de que el sistema esté en un estado de energía E_0 es

$$P(E_0) = \frac{\exp(-\beta E_0)}{\exp(-\beta E_0) + \exp(-\beta E_1)} = \frac{1}{1 + \exp(-\beta \Delta E)} \quad (8)$$

y para un estado de energía E_1

Para entender la regresión logística, consideremos un sistema de dos estados cuyas energías son E_0 y E_1 , la probabilidad de que el sistema esté en un estado de energía E_0 es

$$P(E_0) = \frac{\exp(-\beta E_0)}{\exp(-\beta E_0) + \exp(-\beta E_1)} = \frac{1}{1 + \exp(-\beta \Delta E)} \quad (8)$$

y para un estado de energía E_1

$$P(E_1) = 1 - P(E_0) \quad (9)$$


Regresión logística

Con el modelo de regresión logística lo que esperamos es realizar una clasificación de un conjunto de datos binario, a través de

$$P(y_i = 1|\mathbf{x}_i, \theta) = \frac{1}{1 + \exp(-\mathbf{x}_i^T \theta)} = \sigma(\mathbf{x}_i^T \theta)$$

y

$$P(y_i = 0|\mathbf{x}_i, \theta) = 1 - P(y_i = 1|\mathbf{x}_i, \theta)$$



Para realizar el entrenamiento de este clasificador, usaremos la función de costo

$$c(\theta) = - \sum_{i=1}^n (y_i \log \sigma(\mathbf{x}_i^T \theta) + (1 - y_i) \log(1 - \sigma(\mathbf{x}_i^T \theta))).$$

También conocida como entropía cruzada.


Regresión Logística y Modelo de Ising

Usando el modelo de regresión logística, podemos realizar una clasificación de los estados de Ising de acuerdo a su fase. Recordemos que el Hamiltoniano del modelo de Ising clásico es

$$H = -J \sum_{\langle ij \rangle} S_i S_j,$$

con $S_j \in \{\pm 1\}$ y J la constante de interacción.

Clasificación




- Tenemos una fase ordenada (ferromagnética).
- Onsager demostró que que este modelo sufre un transición de fase a una temperatura crde T_c/J approx 2.26.
- Fase desordenada.

Para aplicar regresión logística al modelo de Ising para las dos fases:

- Consideramos un lattice cuadrado de tamaño 40×40 y usando montecarlo se preparan 10^4 estados variando la temperatura.
- Para entrenar el clasificador, usamos descenso de gradiente estocástico usando configuraciones con temperaturas $T/J < 2,0$, $2,0 \leq T/J \leq 2,5$ y $T/J > 2,4$.
- Una vez entrenado el clasificador, evaluamos el desempeño del clasificador en estados de prueba.

Clasificación

La siguiente gráfica muestra los resultados, variando un hiperparámetro del gradiente de descenso estocástico



- Machine Learning es una herramienta poderosa incluso con modelos simples. Los cuales pueden ser utilizados en física para extraer información.
- En muchos de los modelos como regresión logística y redes neuronales existe una conexión con la física estadística.